

**FUNDAÇÃO GETULIO VARGAS  
EPGE - ESCOLA BRASILEIRA DE ECONOMIA E FINANÇAS**

**KAYO FRANCISCO DA SILVA**

**FATORES MACROECONÔMICOS PARA PREVISÃO DE RETORNOS E  
OTIMIZAÇÃO DE CARTEIRAS COM ATIVOS DA B3**

**RIO DE JANEIRO, RJ  
2026**

**KAYO FRANCISCO DA SILVA**

**FATORES MACROECONÔMICOS PARA PREVISÃO DE RETORNOS E  
OTIMIZAÇÃO DE CARTEIRAS COM ATIVOS DA B3**

Projeto de pesquisa apresentado à FGV EPGE  
- Escola Brasileira de Economia e Finanças da  
Fundação Getulio Vargas, como requisito para a  
elaboração do Trabalho de Conclusão de Curso  
(TCC II).

**Área de concentração:** Finanças

**Orientador:** Prof. Dr. Claudio Henrique da  
Silveira Barbedo

**RIO DE JANEIRO, RJ  
2026**

**FUNDAÇÃO GETULIO VARGAS**  
**EPGE - ESCOLA BRASILEIRA DE ECONOMIA E FINANÇAS**

**FICHA DE APROVAÇÃO DO PROJETO DE TCC I**

**Discente:** Kayo Francisco da Silva

**Matrícula:** 231201009

**Título do Projeto:** Fatores Macroeconômicos para Previsão de Retornos e Otimização de Carteiras com Ativos da B3

**Linha de pesquisa (se aplicável):** Finanças

Declaro, para os devidos fins, que esse projeto de trabalho de conclusão de curso foi apresentado na data abaixo e avaliado nos termos do plano de ensino da disciplina TCC I, encontrando-se:

☐ Aprovado

☐ Aprovado com ajustes

☐ Reprovado

Data da apresentação:

Prof. Orientador

Nome: Claudio Henrique da Silveira Barbedo

Assinatura: \_\_\_\_\_

Prof. da Disciplina TCC I

Nome: Janaína Rodrigues Feijó

Assinatura: \_\_\_\_\_

Discente (Ciência)

Nome: Kayo Francisco da Silva

Assinatura: \_\_\_\_\_

## **LISTA DE TABELAS**

|                                                           |    |
|-----------------------------------------------------------|----|
| Tabela 1 – Cronograma de Execução da Monografia . . . . . | 15 |
|-----------------------------------------------------------|----|

## LISTA DE SIGLAS

|    |                  |
|----|------------------|
| ML | Machine Learning |
| RF | Random Forest    |

## SUMÁRIO

|     |                                                   |    |
|-----|---------------------------------------------------|----|
| 1   | INTRODUÇÃO . . . . .                              | 6  |
| 2   | PROBLEMA DE PESQUISA . . . . .                    | 7  |
| 3   | OBJETIVOS . . . . .                               | 8  |
| 3.1 | Objetivo Geral . . . . .                          | 8  |
| 3.2 | Objetivos Específicos . . . . .                   | 8  |
| 4   | JUSTIFICATIVA . . . . .                           | 9  |
| 5   | REFERENCIAL TEÓRICO . . . . .                     | 10 |
| 5.1 | Otimização de Carteiras . . . . .                 | 10 |
| 5.2 | Previsão de Retornos . . . . .                    | 10 |
| 5.3 | Medidas de Desempenho Ajustado ao Risco . . . . . | 11 |
| 6   | METODOLOGIA E DADOS . . . . .                     | 13 |
| 6.1 | Metodologia . . . . .                             | 13 |
| 6.2 | Dados . . . . .                                   | 14 |
| 7   | CRONOGRAMA . . . . .                              | 15 |
| 8   | RESULTADOS ESPERADOS . . . . .                    | 16 |
|     | REFERÊNCIAS . . . . .                             | 17 |

## 1 INTRODUÇÃO

Para Markowitz (1952), "o investidor considera (ou deveria) o retorno esperado como algo desejável e a variância do retorno como algo indesejável". Essa afirmação consolidou retorno esperado e variância como fatores no problema de otimização de portfólios, no qual o investidor racional enfrenta um *trade-off* entre obter um maior retorno e, ao mesmo tempo, arriscar-se o mínimo possível. (MARKOWITZ, 1952) No entanto, preços, retornos e variâncias não são constantes no tempo, e variam em função de mudanças econômicas, políticas ou expectativas do mercado. Por isso, a incorporação de fatores macroeconômicos pode fornecer informações relevantes para a previsão de retornos e, portanto, para a formação das carteiras. (FAMA; FRENCH, 1989)

Considerando que o desempenho dos ativos é incerto e altamente dependente de previsões sobre o desempenho do mercado de ações, diferentes técnicas são utilizadas para prever o desempenho futuro dos ativos, como modelos econométricos ou de aprendizado de máquina (*machine learning* - ML). Nesse sentido, há amplo espaço para o desenvolvimento de técnicas para melhorias e otimização de carteiras, sobretudo quando se considera que a formação de portfólios depende da estimação dos retornos esperados e dos riscos associados aos ativos. (BEHERA et al., 2023)

Com base nisso, esse trabalho tem como propósito avaliar se a incorporação de fatores macroeconômicos contribui para a formação de carteiras arriscadas com melhor desempenho ajustado ao risco no mercado brasileiro. Para isso, serão utilizados modelos de ML para prever retornos futuros de ativos da Bolsa de Valores brasileira (B3), incorporando fatores macroeconômicos como variáveis adicionais. Adicionalmente, as previsões obtidas serão utilizadas para construir carteiras otimizadas, seguindo o framework de Kaczmarek e Perez (2022), que aplicam *Random Forest* (RF) para prever retornos e formar carteiras em mercados desenvolvidos. (BEHERA et al., 2023; KACZMAREK; PEREZ, 2022)

Nesse sentido, (KACZMAREK; PEREZ, 2022) propõem um framework que utiliza RF para prever retornos esperados de ações a partir de variáveis macroeconômicas e características dos ativos, selecionando os melhores ativos para formar carteiras otimizadas. Os autores aplicam essa abordagem aos mercados norte-americano e europeu, obtendo carteiras com desempenho superior aos benchmarks simples. Este trabalho adapta o núcleo desse artigo ao mercado brasileiro, utilizando um conjunto reduzido de variáveis. (KACZMAREK; PEREZ, 2022)

Por fim, o desempenho das carteiras formadas será comparado com alternativas simples, como o retorno geral do mercado, uma carteira equiponderada e carteiras construídas sem a inclusão de fatores macroeconômicos. Essa comparação será feita a partir de métricas de retorno, risco e desempenho ajustado ao risco, buscando avaliar se a incorporação de informações macroeconômicas contribui para a formação de carteiras com melhor relação entre retorno e risco. (SHARPE, 1998)

## 2 PROBLEMA DE PESQUISA

A incorporação de fatores macroeconômicos, como taxa de juros nominal e spread da curva de juros, em modelos de *machine learning* para a previsão de retornos, contribui para a formação de carteiras arriscadas com melhor desempenho ajustado ao risco no mercado de ações brasileiro? Isto é, carteiras construídas a partir de previsões que incorporam informações macroeconômicas apresentam desempenho superior às carteiras baseadas somente em informações históricas dos ativos?



### 3 OBJETIVOS

#### 3.1 Objetivo Geral

Avaliar se a incorporação de fatores macroeconômicos melhora o desempenho ajustado ao risco de carteiras construídas a partir de ativos do mercado acionário brasileiro, considerando a previsão de retornos de ativos da B3 e o desempenho em termos de retorno e risco.

#### 3.2 Objetivos Específicos

- Utilizar modelos de *machine learning* para prever retornos futuros de ativos da B3 a partir de retornos passados e variáveis macroeconômicos
- Construir carteiras a partir das previsões de retornos dos ativos, buscando a melhor relação entre retorno e risco
- Comparar a carteira formada com modelos alternativos, como carteira equiponderada e carteira otimizada sem considerar fatores macroeconômicos

## 4 JUSTIFICATIVA

A formação de carteiras é um tema central em finanças, já que envolve a alocação de recursos entre diferentes ativos diante da relação entre retorno e risco. Dado que o desempenho dos ativos é incerto e depende de previsões sobre o comportamento do mercado, a utilização de variáveis capazes de capturar mudanças nas condições econômicas pode contribuir para decisões de alocação mais bem fundamentadas. Em economias dinâmicas como a brasileira, fatores como taxa de juros nominal e spread da curva de juros são especialmente relevantes, pois impactam a percepção de risco no mercado, os custos de oportunidade e a atratividade relativa dos ativos de risco.

Além disso, com o avanço recente de técnicas de inteligência artificial e *machine learning*, abre-se amplo espaço para o desenvolvimento de aplicações em diferentes áreas, incluindo finanças. Nesse contexto, modelos de ML podem ser utilizados como ferramentas auxiliares para lidar com relações não lineares e padrões complexos nos dados financeiros, especialmente em problemas de previsão de retornos. No entanto, sua aplicação à formação de carteiras exige uma análise cuidadosa, já que previsões aparentemente melhores não necessariamente se traduzem em carteiras com melhor desempenho ajustado ao risco.

Dessa forma, a relevância deste trabalho está em aproximar a literatura de previsão de retornos e otimização de carteiras de uma aplicação voltada ao mercado acionário brasileiro. Ao considerar ativos da B3 e variáveis associadas às condições macroeconômicas, a pesquisa busca dialogar com um contexto em que mudanças na taxa de juros, na curva de juros e na percepção de risco podem afetar de forma importante as decisões de alocação. Além disso, o uso de modelos de ML permite explorar ferramentas recentes de previsão em finanças, sem restringir a análise apenas a métodos tradicionais. Assim, o trabalho se justifica por investigar uma aplicação prática e atual para a gestão de portfólios, contribuindo para a discussão sobre como informações econômicas podem ser incorporadas ao processo de formação de carteiras.

## 5 REFERENCIAL TEÓRICO

Nesta seção, serão apresentados os principais estudos relacionados à previsão de retornos de ativos, à otimização de carteiras e à mensuração de risco. Com isso, os trabalhos discutidos a seguir servem como base para este trabalho, contextualizando o tema e justificando a abordagem adotada.

### 5.1 Otimização de Carteiras

Segundo Markowitz (1952), a seleção de portfólios ocorre a partir de dois processos: primeiro, criam-se expectativas sobre os retornos futuros dos ativos; em seguida, com os resultados da primeira etapa, o portfólio ótimo é escolhido, buscando uma relação ótima entre retorno e risco. Para isso, o autor assume que o investidor é avesso ao risco, de modo que busca maximizar retornos e, ao mesmo tempo, minimizar riscos. Dessa forma, no modelo, métricas de retorno e risco (aqui definidas como retorno futuro esperado e variância) são fundamentais para a análise de ativos e carteiras arriscadas. (MARKOWITZ, 1952)

Assumindo uma carteira com  $N$  ativos, com retornos  $r_i$  e variâncias  $\sigma_i^2$ ,  $i \in (1, 2, \dots, N)$ , e tomando  $X = (x_1, x_2, \dots, x_N)$  como o vetor de proporções de cada ativo na carteira ( $\sum_{i=1}^N x_i = 1$ ), conclui-se que retorno e variância da carteira ( $c$ ) são dados por:

$$R_c = \sum_{i=1}^N r_i x_i \quad \sigma_c^2 = \sum_{i=1}^N x_i^2 \sigma_i^2 + 2 \sum_{i=1}^N \sum_{j>i}^N x_i x_j \sigma_{ij}$$

onde  $\sigma_{ij} = E\{[r_i - E[r_i]] \times [r_j - E[r_j]]\}$  define a covariância entre os ativos  $i$  e  $j$ , que também pode ser expresso em termos do coeficiente de correlação entre  $i$  e  $j$ :  $\sigma_{ij} = \rho_{ij} \sigma_i \sigma_j$ . (MARKOWITZ, 1952)

Com isso, sabendo que o risco da carteira não depende somente dos riscos de cada um dos ativos que a compõem, mas também da correlação entre esses ativos, o artigo conclui que a diversificação do portfólio pode ser útil para obter uma melhor relação entre retorno e risco. Para maximizarmos essa relação, contudo, não basta selecionar diversos ativos aleatórios, mas sim buscar por aqueles que são pouco correlacionados; a lógica é que empresas de setores distintos têm menor probabilidade de performar mal ao mesmo tempo que duas empresas do mesmo setor. (MARKOWITZ, 1952)

### 5.2 Previsão de Retornos

Como visto em 5.1, a busca pela otimização de um portfólio depende diretamente das expectativas de retornos futuros dos ativos disponíveis. Nesse sentido, a capacidade de fazer boas previsões sobre o desempenho desses ativos é fundamental para a construção de uma boa carteira.

Com isso, Behera et al. (2023) aponta que muitos modelos utilizam econometria para tentar prever preços futuros; contudo, aponta que modelos de ML têm ganhado força e se mostrado melhores para lidar com dificuldades não estacionárias e não lineares. A partir disso, o autor utiliza diversos modelos de ML para prever retornos futuros de ações das bolsas de Bombaim, Tóquio e Xangai. Como resultado, o artigo conclui que o modelo AdaBoost, que combina uma série de classificadores fracos para criar um classificador forte, é o que obtém melhor desempenho nas previsões. O artigo reconhece, contudo, limitações no estudo realizado, em especial o fato da previsão ter sido construída apenas a partir de dados históricos sobre os ativos. (BEHERA et al., 2023)

Portanto, conforme sugerido por Fama e French (1989), fatores macroeconômicos serão incorporados no modelo de previsão, uma vez que condições econômicas apresentam relação com a variação dos retornos esperados. No estudo, os autores mostram que retornos esperados de ações variam conforme as condições de negócios, utilizando variáveis como *term spread*. Além disso, a taxa básica de juros nominal será utilizada por representar uma dimensão importante das condições macroeconômicas, afetando custos de oportunidade e a atratividade dos ativos de risco. (FAMA; FRENCH, 1989)

Nesse sentido, Kaczmarek e Perez (2022) propõem um framework que integra diretamente a previsão de retornos por RF à formação de carteiras. Os autores utilizam variáveis macroeconômicas e características das ações como preditores, selecionam os ativos com maiores retornos previstos e constroem carteiras otimizadas, comparando o desempenho com benchmarks simples. Este trabalho adapta esse framework ao mercado brasileiro, com simplificações justificadas pelo escopo e pelos dados disponíveis. (KACZMAREK; PEREZ, 2022)

### 5.3 Medidas de Desempenho Ajustado ao Risco

Esta seção apresenta medidas de desempenho relevantes para a avaliação das carteiras formadas. Será considerado o Índice de Sharpe, utilizado para comparar o retorno obtido em relação ao risco assumido.

Em Sharpe (1998), o Índice apresentado pelo autor busca, em uma única medida, representar a relação entre retorno e risco do ativo ou carteira analisado. Utilizando  $r_f$  para a taxa livre de risco,  $r_c$  para o retorno da carteira e  $\sigma_c$  para o desvio padrão, a versão mais simples do Índice de Sharpe, ex-ante, é definido por:

$$S \equiv \frac{r_c - r_f}{\sigma_c}$$

o que indica o retorno adicional esperado por unidade de risco. Na versão ex-post, consideramos o retorno diferencial, sua média e o desvio padrão, e obtemos a seguinte relação:

$$S_h = \frac{\frac{1}{T} \sum_{t=1}^T (r_{ct} - r_{ft})}{\sqrt{\frac{\sum_{t=1}^T [(r_{ct} - r_{ft}) - \frac{1}{T} \sum_{s=1}^T (r_{cs} - r_{fs})]^2}{T-1}}}$$

onde  $t \in T$  representa cada um dos períodos. Nesse caso, o índice indica o retorno adicional médio por unidade de variabilidade histórica de retorno. Com isso, o Índice de Sharpe será

utilizado no trabalho para comparar o desempenho ajustado ao risco das carteiras formadas.  
(SHARPE, 1998)

## 6 METODOLOGIA E DADOS

A construção das carteiras terá como base a relação entre retorno e risco apresentada por Markowitz. O desempenho das carteiras será comparado com alternativas de referência, como o retorno geral do mercado e uma carteira equiponderada. A análise será feita por métricas de retorno, risco e desempenho ajustado ao risco.

### 6.1 Metodologia

A pesquisa será empírica, quantitativa e aplicada, buscando avaliar se fatores macroeconômicos melhoram a previsão de retornos por modelos de ML e, com isso, a formação de carteiras no mercado brasileiro. A metodologia deriva de uma adaptação de Kaczmarek e Perez (2022) para o contexto brasileiro, com simplificações estabelecidas para melhor se adaptar ao escopo do trabalho.

O estudo será conduzido em três etapas. Primeiro, serão coletados dados de preços de ações da B3 e variáveis macroeconômicas, como taxa de juros nominal e spread da curva de juros. Em seguida, os retornos dos ativos serão previstos por modelos de ML, em especial RF, utilizando retornos passados e fatores macroeconômicos como variáveis explicativas. Por fim, as previsões obtidas serão usadas para construir carteiras otimizadas, cujas performances serão avaliadas em relação ao risco assumido.

A etapa de previsão seguirá a abordagem de Kaczmarek e Perez (2022), em que o retorno esperado de cada ativo  $i$  no período  $t$  é estimado por um modelo *Random Forest* a partir de um vetor de variáveis preditoras defasadas:

$$\hat{r}_{i,t} = f(X_{i,t-1})$$

onde  $f(\cdot)$  representa o modelo RF e  $X_{i,t-1}$  contém os retornos passados do ativo e as variáveis macroeconômicas disponíveis no período anterior. O modelo será estimado em janela *rolling*, garantindo que as previsões sejam sempre realizadas fora da amostra de treinamento.

A construção das carteiras terá como base a relação entre retorno e risco apresentada por Markowitz. Assim, considerando uma carteira com  $N$  ativos, o retorno e a variância da carteira podem ser representados por:

$$R_c = \sum_{i=1}^N r_i x_i \quad \sigma_c^2 = \sum_{i=1}^N x_i^2 \sigma_i^2 + 2 \sum_{i=1}^N \sum_{j>i}^N x_i x_j \sigma_{ij}$$

em que  $x_i$  representa a participação do ativo  $i$  na carteira,  $r_i$  representa seu retorno,  $\sigma_i^2$  sua variância e  $\sigma_{ij}$  a covariância entre os ativos  $i$  e  $j$ . A partir dessa estrutura, os retornos previstos pelos modelos serão utilizados na formação das carteiras.

O desempenho das carteiras será comparado com alternativas de referência, como uma carteira equiponderada e o retorno geral do mercado. A análise será feita por métricas de retorno, risco e desempenho ajustado ao risco.

## **6.2 Dados**

Serão utilizados dados de preços de ações negociadas na B3, a partir dos quais serão calculados os retornos dos ativos. A amostra utilizada contemplará o período de 2015 a 2025.

Além disso, serão coletadas variáveis macroeconômicas associadas às condições financeiras da economia brasileira, especialmente taxa de juros nominal e spread da curva de juros. As variáveis macroeconômicas serão obtidas do Banco Central do Brasil, e é esperado que incorporem informações relevantes sobre as condições financeiras da economia brasileira aos modelos de previsão.

## 7 CRONOGRAMA

A execução da pesquisa será dividida em etapas, começando pela revisão da literatura e pela coleta dos dados, seguida pelo tratamento das bases, estimação dos modelos e análise dos resultados. Após essas etapas, serão realizados os aperfeiçoamentos necessários e a redação final da monografia. A Tabela 1 apresenta a organização prevista dessas atividades ao longo do período de desenvolvimento do trabalho.

**Tabela 1 – Cronograma de Execução da Monografia**

| <b>Etapas</b>          | <b>Julho</b> | <b>Agosto</b> | <b>Setembro</b> | <b>Outubro</b> | <b>Novembro</b> | <b>Dezemb</b> |
|------------------------|--------------|---------------|-----------------|----------------|-----------------|---------------|
| Revisão da literatura  | x            | x             | x               |                |                 |               |
| Coleta de dados        |              | x             | x               |                |                 |               |
| Tratamento dos dados   |              |               | x               | x              |                 |               |
| Estimações             |              |               |                 | x              | x               |               |
| Análise dos Resultados |              |               |                 |                | x               | x             |
| Aperfeiçoamentos       |              |               |                 |                |                 | x             |
| Redação Final          |              |               |                 |                | x               | x             |

Fonte: elaboração própria.



## 8 RESULTADOS ESPERADOS

Espera-se que o trabalho contribua para avaliar, de forma aplicada, se a incorporação de fatores macroeconômicos em modelos de ML pode auxiliar na previsão de retornos de ativos da B3 e na formação de carteiras com melhor relação entre retorno e risco. A partir da comparação entre carteiras construídas com e sem essas variáveis, pretende-se verificar se informações como taxa de juros nominal e spread da curva de juros acrescentam poder explicativo relevante ao processo de alocação.

Além disso, espera-se que a pesquisa permita discutir o uso de métricas de desempenho ajustado ao risco para comparar diferentes estratégias. Dessa forma, o trabalho busca oferecer evidências iniciais sobre a combinação entre previsão de retornos, fatores macroeconômicos e machine learning no mercado acionário brasileiro.

## Referências

BEHERA, J. et al. Prediction based mean-value-at-risk portfolio optimization using machine learning regression algorithms for multi-national stock markets. *Engineering Applications of Artificial Intelligence*, Elsevier, v. 120, p. 105843, 2023.

FAMA, E. F.; FRENCH, K. R. Business conditions and expected returns on stocks and bonds. *Journal of Financial Economics*, v. 25, n. 1, p. 23–49, 1989. ISSN 0304-405X. Disponível em: <<https://www.sciencedirect.com/science/article/pii/0304405X89900950>>.

KACZMAREK, T.; PEREZ, K. Building portfolios based on machine learning predictions. *Economic research-Ekonomska istraživanja*, Taylor and Francis Group, v. 35, n. 1, p. 19–37, 2022.

MARKOWITZ, H. Portfolio selection. *The Journal of Finance*, v. 7, n. 1, p. 77–91, 1952. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1540-6261.1952.tb01525.x>>.

SHARPE, W. F. The sharpe ratio (fall 1994). In: \_\_\_\_\_. *Streetwise*. Princeton: Princeton University Press, 1998. p. 169–178. ISBN 9781400829408. Disponível em: <<https://doi.org/10.1515/9781400829408-022>>.